

République Algérienne Démocratique et Populaire
Ministère de l'Enseignement Supérieur et de la Recherche Scientifique

Higher Institute of Sciences



Projet de fin d'étude

En : Mathématiques et Informatique

Spécialité : Ingénierie de Systèmes d'Information & Logiciels

Intitulé :

Vectorization Automatique d'Images Matricielles par Deep Learning

Encadré par :

ABDELLAHOUM Hamza

Présenté par :

BITAM Amir

AITHAMOUDI Zakaria

Membres du Jury :

????

????

Soutenu le :

??/07/2026

Année universitaire : 2025/2026

Remerciements

Nous tenons à exprimer notre profonde gratitude envers Allah, le Tout-Puissant, pour nous avoir accordé la force, la patience et la persévérance nécessaires pour mener à bien ce projet de fin d'étude.

Nous remercions sincèrement notre encadreur **ABDELLAHOU** **Hamza** pour sa précieuse guidance, son soutien constant et ses précieux conseils tout au long de ce projet.

Nos vifs remerciements s'adressent également aux membres du jury **????** et **????** pour avoir accepté d'évaluer notre travail.

Dédicace

Résumé

Nous proposons dans le cadre de notre projet de fin d'études un modèle d'IA qui traite le zoom et le dézoom dans les images numériques. En zoomant sur une image de taille donnée, sa qualité est souvent altérée et l'image peut devenir pixélisée. Notre travail consiste à améliorer ces images en augmentant leur qualité.

En ce qui concerne le dézoom, en réduisant les dimensions de l'image, il faut minimiser le nombre de pixels tout en préservant l'esthétique de l'image.

Nous avons créé un modèle CNN avec une architecture adaptée, piloté par des métaheuristiques (algorithme génétique) permettant de sélectionner les paramètres optimaux afin d'obtenir de bonnes performances avec un nombre minimal de paramètres.

Mots-clés : Redimensionnement d'images, Super Résolution, Réseaux de Neurones Convolutifs (CNN), Algorithme Génétique, Métaheuristiques, PSNR, SSIM.

Abstract

Keywords : Image Resizing, Super Resolution, Convolutional Neural Networks (CNN), Genetic Algorithm, Metaheuristics, PSNR, SSIM.

Liste des Acronymes

XML	eXtensible Markup Language
SVG	Scalable Vector Graphics
GA	Genetic Algorithm
CNN	Convolutional Neural Networks
PSNR	Peak Signal to Noise Ratio
HR	High Resolution
LR	Low Resolution
SSIM	Structural SIMilarity
SRCNN	Super Resolution Convolutional Neural Network
SRGAN	Super Resolution Generative Adversarial Network
MAE	Mean Absolute Error
MSE	Mean Squared Error
ReLU	Rectified Linear Unit
ResNet	Residual Network
SE	Squeeze-and-Excitation
CAR	Content Adaptive Resampler
FARF	Feature Augmented Random Forest
DRDN	Deep Residual Dense Network
EDSAN	Enhanced Dense Space Attention Network
PPI	Pixels Per Inch

Table des matières

Remerciements	i
Dédicace	ii
Résumé	iii
Abstract	iv
Liste des Acronymes	v
Introduction Générale	2
1 État de l'Art	3
1.1 Introduction	3
1.2 Définitions liées à la vectorisation d'images	3
1.2.1 Images matricielles	3
1.2.1.1 Pixels	4
1.2.2 Images vectorielles	4
1.2.2.1 Courbes de Bézier	4
1.2.2.2 Format SVG	4
1.3 Apprentissage automatique	5
1.3.1 Apprentissage automatique	5
1.3.1.1 Non supervisé	5
1.3.2 Apprentissage profond	5
1.3.2.1 Introduction aux réseaux de neurones	5
1.3.2.2 Réseaux de neurones multicouches	5
1.3.2.3 Réseaux de neurones multicouches	5
1.3.2.4 Transformeurs	5
1.3.2.4.1 Attention	5
1.3.2.4.2 Auto attention	5
1.3.2.4.3 Attention croisée	5
1.3.3 Fonction de perte	6
1.3.4 Fonction de coût	6
1.3.5 Fonction d'activation	6
1.4 Évaluation des résultats	6
1.4.1 Mean Squared Error (MSE)	6
1.4.2 Peak Signal-to-Noise Ratio (PSNR)	6

1.4.3	Learned Perceptual Image Patch Similarity (LPIPS)	6
1.4.4	Structural Similarity index (SSIM)	6
1.5	Travaux connexes	6
1.5.1	Approche algorithmique	6
1.5.1.1	(Potrace)	6
1.5.2	Approche d'optimisation	6
1.5.2.1	(DIFFVG)	6
1.5.2.2	(LIVE)	6
1.5.3	Approche d'apprentissage profond	6
1.5.3.1	IM2VEC	6
1.5.3.2	SuperSVG	6
1.6	Problématique	6
1.7	Conclusion	6
2	Approche Proposée	7
2.1	Introduction	7
2.2	Dataset et prétraitement	7
2.2.1	Le prétraitement des données	7
2.2.1.1	Former les paires d'images	7
2.2.1.2	Augmentation de données	7
2.3	Méthode proposée	7
2.3.1	Définir les hyperparamètres évalués par les métaheuristiques . .	7
2.3.1.1	L'Algorithme Génétique	7
2.3.1.2	Les paramètres à optimiser	7
2.3.1.3	Évaluation d'une solution	7
2.3.2	Architecture	7
2.3.2.1	Sur-échantillonnage (Upsampling)	7
2.3.2.2	Sous-échantillonnage (Downsampling)	7
2.4	Conclusion	7
3	Expérimentations et Résultats	8
3.1	Introduction	8
3.2	Environnement de développement	8
3.2.1	Hardware	8
3.2.2	Software	8
3.3	Dataset utilisé	8
3.4	Prétraitement	8
3.5	Évaluation	8
3.5.1	Évaluation quantitative	8
3.5.2	Fonction de perte	8

3.6	Paramétrage de l'Algorithme Génétique	8
3.7	Sous-échantillonnage	9
3.7.1	Hyperparamètres avec la métaheuristique (GA)	9
3.7.2	Résultats	9
3.7.2.1	Résultats quantitatifs	9
3.7.2.2	Résultats qualitatifs	9
3.8	Sur-échantillonnage	9
3.8.1	Hyperparamètres	9
3.8.2	Résultats	10
3.8.2.1	Résultats quantitatifs	10
3.8.2.2	Résultats qualitatifs	10
3.9	Conclusion	10
	Conclusion Générale	11
	Bibliographie	12

Table des figures

1.1	Comparaison entre une image matricielle (gauche) sujette à la pixellisation lors de l'agrandissement, et une image vectorielle (droite) conservant sa netteté grâce à sa définition mathématique	4
1.2	Exemple du contenu d'un fichier .svg	5

Liste des tableaux

3.1	Spécifications de la machine Kaggle	8
3.2	Valeurs du PSNR en fonction du nombre de générations	9
3.3	Résultats du downsampling (Set5) — PSNR / SSIM	9
3.4	Comparaison quantitative sur Set5 (PSNR en dB)	10

Introduction Générale

Le traitement d'images est un domaine de recherche important qui trouve des applications dans divers domaines tels que la médecine, la surveillance, la sécurité, la robotique, l'automobile, etc.

L'un des problèmes les plus courants dans ce domaine est la qualité de l'image qui peut être altérée lorsqu'elle est agrandie ou réduite en taille.

Ce mémoire est organisé comme suit :

- **Chapitre 1** : État de l'art — revue de littérature sur le redimensionnement d'images et les approches existantes.
- **Chapitre 2** : Approche proposée — architecture des modèles CNN et sélection des hyperparamètres par méta heuristiques.
- **Chapitre 3** : Expérimentations et Résultats — évaluation quantitative et qualitative avec comparaisons.

Chapitre 1

État de l'Art

1.1 Introduction

L'intelligence artificielle par le biais de l'apprentissage automatique a imposé un changement de paradigme dans de nombreux domaines[1], en particulier l'informatique et ses différentes disciplines. La vision par ordinateur est un parfait exemple de ce changement de paradigme, où la spécialité s'est dirigé de l'application d'algorithmes "naïf" à l'utilisation de réseaux de neurones pour le traitement et l'extraction d'informations de l'image, cette évolution dans les techniques utilisées par la vision par ordinateur est illustré dans l'évolution de la vectorisation d'images. Dans ce chapitre, nous exposerons d'abord les concepts clés à la vectorisation d'images, à l'apprentissage automatique, et les architectures utilisées tout au long de ce travail, ceci nous permettra de mieux appréhender ensuite les travaux effectués sur le sujet.

1.2 Définitions liées à la vectorisation d'images

Dans cette section nous tenterons de définir les termes et concepts lié à la transformation d'image matricielles en images vectorielles, dite, vectorisation d'images. En soulignant notamment la différence entre les images dites matricielles et vectorielles. En opposant ainsi les deux types d'images nous pourrions mieux cerner la motivation derrière ce travail et pourquoi la vectorisation d'image constitue un exercice complexe de la vision par ordinateur.

1.2.1 Images matricielles

Les images matricielles pourrait être décrites de la même manière que [2] le fait, soit des fonction bidimensionnelles $f(x, y)$, où x et y sont des coordonnées spatiales planes et où f associerait à chaque paire une amplitude ou valeur correspondante, ou plus simplement comme étant une carte ou grille de points de pixels, de largeur et de hauteur donné. Par définition les images matricielles présente une limite lié à l'agrandissement de l'image, Effectivement, plus l'image est agrandi plus la perte de détails s'accroît, la mise à l'échelle est donc impossible par la nature fixe du nombre de pixels constituant l'image.

1.2.1.1 Pixels

1.2.2 Images vectorielles

Les images vectorielles sont décrites par un ensemble de formes géométriques individuelles : (cercles, segments de droites, courbes de Bézier, etc.), chacune de ces formes est enregistrée accompagnée de paramètres mathématiques et attributs la décrivant (couleur de remplissage, point d'ancrage, etc.). Contrairement aux images représentées sous forme matricielles où les pixels sont figés, ici les images offrent une possibilité d'agrandissement théoriquement infini, et cela sans dégrader la qualité de l'image en question car le rendu image est calculé de nouveau pour chaque résolution [3]. Les images vectorielles sont donc très utilisées dans le graphisme et la conception, rendant donc le passage d'image matricielle à une image vectorielle d'autant plus critique pour ces domaines d'application, mais aussi complexe dû à la nature différente des représentations matricielle et vectorielle.




FIGURE 1.1 – Comparaison entre une image matricielle (gauche) sujette à la pixellisation lors de l'agrandissement, et une image vectorielle (droite) conservant sa netteté grâce à sa définition mathématique

1.2.2.1 Courbes de Bézier

Une courbe de Bézier est définie comme une fonction polynomiale dont la forme est dictée par la position de points de contrôle. La courbe passe par le premier et le dernier point (points d'ancrage), tandis que les points intermédiaires agissent comme des "aimants" qui tirent la courbe vers eux. Les courbes de Bézier font partie des formes géométriques individuelles qui composent les images vectorielles et se distinguent par le faible nombre de données numériques nécessaires à la représentation de formes complexes.

1.2.2.2 Format SVG

SVG (Scalable Vector Graphics) est un format basé sur XML comportant des directives pour la définition de graphiques 2D[4]. Stockées dans des fichiers textes rendant les SVG compressibles et indexables, ces directives SVG supportent aussi bien les

formes géométriques vectorielle que les images et le texte. Pour les raisons précédentes ce sera ce format qui sera préféré pour la sortie du modèle.

```
<?xml version="1.0" encoding="UTF-8" standalone="no"?>
<!DOCTYPE svg PUBLIC "-//W3C//DTD SVG 1.1//EN" "http://
www.w3.org/Graphics/SVG/1.1/DTD/svg11.dtd">
<svg width="391" height="391" viewBox="-70.5 -70.5 391 391"
xmlns="http://www.w3.org/2000/svg" xmlns:xlink="http://
www.w3.org/1999/xlink">
  <rect fill="#fff" stroke="#000" x="-70" y="-70" width="390"
height="390"/>
  <g opacity="0.8">
    <rect x="25" y="25" width="200" height="200" fill="lime"
stroke-width="4" stroke="pink" />
    <circle cx="125" cy="125" r="75" fill="orange" />
    <polyline points="50,150 50,200 200,200 200,100" stroke="red"
stroke-width="4" fill="none" />
    <line x1="50" y1="50" x2="200" y2="200" stroke="blue" stroke-
width="4" />
  </g>
</svg>
```

FIGURE 1.2 – Exemple du contenu d'un fichier .svg

1.3 Apprentissage automatique

1.3.1 Apprentissage automatique

Supervisé

1.3.1.1 Non supervisé

1.3.2 Apprentissage profond

1.3.2.1 Introduction aux réseaux de neurones

1.3.2.2 Réseaux de neurones multicouches

1.3.2.3 Réseaux de neurones multicouches

1.3.2.4 Transformeurs

1.3.2.4.1 Attention

1.3.2.4.2 Auto attention

1.3.2.4.3 Attention croisée

1.3.3 Fonction de perte

1.3.4 Fonction de coût

1.3.5 Fonction d'activation

1.4 Évaluation des résultats

1.4.1 Mean Squared Error (MSE)

1.4.2 Peak Signal-to-Noise Ratio (PSNR)

1.4.3 Learned Perceptual Image Patch Similarity (LPIPS)

1.4.4 Structural Similarity index (SSIM)

1.5 Travaux connexes

1.5.1 Approche algorithmique

1.5.1.1 (Potrace)

1.5.2 Approche d'optimisation

1.5.2.1 (DIFFVG)

1.5.2.2 (LIVE)

1.5.3 Approche d'apprentissage profond

1.5.3.1 IM2VEC

1.5.3.2 SuperSVG

1.6 Problématique

1.7 Conclusion

Chapitre 2

Approche Proposée

2.1 Introduction

2.2 Dataset et prétraitement

2.2.1 Le prétraitement des données

2.2.1.1 Former les paires d'images

2.2.1.2 Augmentation de données

2.3 Méthode proposée

2.3.1 Définir les hyperparamètres évalués par les métaheuristiques

2.3.1.1 L'Algorithme Génétique

2.3.1.2 Les paramètres à optimiser

2.3.1.3 Évaluation d'une solution

2.3.2 Architecture

2.3.2.1 Sur-échantillonnage (Upsampling)

2.3.2.2 Sous-échantillonnage (Downsampling)

2.4 Conclusion

Chapitre 3

Expérimentations et Résultats

3.1 Introduction

3.2 Environnement de développement

3.2.1 Hardware

TABLE 3.1 – Spécifications de la machine Kaggle

CPU	Mémoire	GPU
1,5 GHz	13 Go RAM + 73,1 Go HDD	Nvidia P100 — 16 Go VRAM

3.2.2 Software

3.3 Dataset utilisé

3.4 Prétraitement

3.5 Évaluation

3.5.1 Évaluation quantitative

3.5.2 Fonction de perte

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (3.1)$$

3.6 Paramétrage de l’Algorithme Génétique

- Taille de population : 10
- Nombre de générations : 6
- Probabilité de mutation : 0,5
- Fonction objective : PSNR

3.7 Sous-échantillonnage

3.7.1 Hyperparamètres avec la métaheuristique (GA)

TABLE 3.2 – Valeurs du PSNR en fonction du nombre de générations

Générations	PSNR (dB)
3	50,079
6	50,219

- Batch size : 19 Kernel size : 3×3
- Epochs : 27 Nombre de filtres : 64
- Nombre de couches : 5
- Learning rate : Adam Optimizer ($10^{-4} \rightarrow 10^{-5}$, limite 5000)

3.7.2 Résultats

3.7.2.1 Résultats quantitatifs

TABLE 3.3 – Résultats du downsampling (Set5) — PSNR / SSIM

Dataset	Facteur	Notre Modèle	Bicubique
Set5	$\times 2$	45,61 / 0,99	36,17 / 0,97
	$\times 3$	44,80 / 0,99	30,35 / 0,94
	$\times 4$	33,85 / 0,97	26,80 / 0,91

3.7.2.2 Résultats qualitatifs

3.8 Sur-échantillonnage

3.8.1 Hyperparamètres

- Batch size : 16 Kernel size : 3×3
- Epochs : 250 Nombre de filtres : 128
- Nombre de blocs résiduels : 12
- Learning rate : Adam Optimizer ($10^{-4} \rightarrow 10^{-5}$, limite 5000)

3.8.2 Résultats

3.8.2.1 Résultats quantitatifs

TABLE 3.4 – Comparaison quantitative sur Set5 (PSNR en dB)

Test set	Facteur	Bicubic	SRGAN	DRDN	EDSAN	CAR	SRCNN	Notre Modèle
Set5	×2	33,66	–	32,95	35,25	34,38	36,66	36,71
	×3	30,39	–	29,18	31,48	–	32,75	32,20
	×4	28,42	29,40	27,35	29,80	28,42	30,49	31,498

3.8.2.2 Résultats qualitatifs

3.9 Conclusion

Conclusion Générale

Au cours de ce projet de fin d'étude, nous avons exploré divers aspects de l'apprentissage profond et de la vision par ordinateur pour résoudre le problème du redimensionnement des images.

Bibliographie

- [1] Vasant DHAR. “The Paradigm Shifts in Artificial Intelligence”. In : *Communications of the ACM* 67.11 (nov. 2024), p. 50-59. DOI : 10.1145/3664804.
- [2] Rafael C. GONZALEZ et Richard E. WOODS. *Digital Image Processing*. 4th. Pearson, 2018, p. 36.
- [3] James D. FOLEY et al. *Computer Graphics : Principles and Practice*. 2nd. Addison-Wesley Professional, 1996, p. 8.
- [4] W3C. *Scalable Vector Graphics (SVG) 1.1 (Second Edition)*. W3C Recommendation. World Wide Web Consortium, 2011. URL : <https://www.w3.org/TR/SVG11/>.